

MA-0711 Análisis de Datos I

Año: IV	Requisitos: MA-0503 Estadística I
Ciclo: VII	Correquisitos: Ninguno
Tipo de curso: Teórico-práctico	Horas semanales: 5
Créditos: 4	Virtualidad: P, PV

Descripción del curso

Este curso está dirigido a estudiantes avanzados que han completado una formación básica en estadística e inferencia, por lo que se ubica en el cuarto año (ciclo VII) de la ruta de matemática aplicada. Introduce la modelación de aprendizaje estadístico y la implementación de métodos de aprendizaje no supervisado y supervisado, de modo que la persona estudiante adquiera herramientas de análisis de datos con aplicaciones en múltiples disciplinas, incluyendo riesgos, seguros, finanzas, demografía y otras ciencias cuantitativas.

La propuesta resume y adapta, al formato de programas de la carrera de Matemática, los contenidos y énfasis de las cartas al estudiantado de **CA-0411 Análisis de Datos I** (ofertas recientes) y el programa existente de **MA-0711 Análisis de Datos I**.

Objetivo general

Fortalecer en el estudiantado las competencias teóricas y analíticas del aprendizaje estadístico para diseñar, implementar y evaluar críticamente modelos de aprendizaje supervisado y no supervisado aplicados a datos reales.

Objetivos específicos

Al finalizar el curso el/la estudiante estará en la capacidad de:

1. Comprender el modelo de aprendizaje estadístico y su relación con el proceso de modelación en ciencia de datos. (SC11, SH05.)
2. Implementar modelos de aprendizaje no supervisado y supervisado en conjuntos de datos de distinta índole. (SC11, SH05.)
3. Analizar los procesos de construcción, validación y calibración de modelos, con especial énfasis en aplicaciones cuantitativas (por ejemplo, riesgos, seguros, finanzas o demografía). (SC11, SH05.)
4. Comunicar resultados de modelación a públicos especializados y no especializados, mediante informes y presentaciones. (SH09.)

Contenidos

La distribución por semanas es orientativa. La persona docente puede reordenar la práctica y profundizar subtemas, sin omitir los contenidos obligatorios. Los ítems marcados como *ampliación* pueden cubrirse según el perfil del grupo y el tiempo disponible.

1. **Introducción al aprendizaje estadístico y al análisis multidimensional (2 semanas):**

- a) Motivación del aprendizaje estadístico; marco de modelación en ciencia de datos; sesgo–varianza; conjuntos de entrenamiento, validación y prueba.
- b) Tabla de datos; nubes de individuos y nubes de variables.
- c) Métrica en un espacio euclidiano y distancia en un espacio afín; métrica de pesos.
- d) Centro de gravedad de la nube; matriz de varianza–covarianza; inercias.

2. Aprendizaje no supervisado (5–6 semanas):

- a) **Análisis en componentes principales (ACP):**
 - 1) Aplicación e interpretación de un ACP.
 - 2) Algoritmo e implementación del ACP.
 - 3) Presentación geométrica y algebraica del ACP.
- b) **Clasificación automática (conglomerados):**
 - 1) Panorama de algoritmos de clasificación automática.
 - 2) Método de k -medias.
 - 3) Método de k -medoïdes.
 - 4) Agrupación (clasificación) jerárquica.
- c) **Ampliaciones de análisis multidimensional** (a criterio docente):
 - 1) Escalamiento multidimensional (*multidimensional scaling*).
 - 2) Análisis de correspondencias simples (AFC).
 - 3) Análisis de correspondencias múltiples (AFCM).

3. Aprendizaje supervisado (6–7 semanas):

- a) Motivación del aprendizaje supervisado.
- b) Método de k vecinos más cercanos (KNN) (*ampliación* o puente hacia evaluación de clasificadores).
- c) **Medición de la calidad de un método supervisado:**
 - 1) Matriz de confusión.
 - 2) Análisis del error y curvas ROC.
- d) **Análisis discriminante:**
 - 1) Enfoque factorial.
 - 2) Enfoque bayesiano / métodos bayesianos asociados.
- e) Árboles de decisión (método CART).
- f) Bosques aleatorios.
- g) Valores de Shapley para explicar la predicción de los modelos.
- h) Máquinas de soporte vectorial.
- i) Validación cruzada y calibración de modelos.

4. Proyecto integrador (transversal; énfasis en las semanas finales):

- a) Planteamiento de una pregunta de investigación y uso de datos reales.
- b) Aplicación de al menos un método de aprendizaje supervisado o no supervisado *no desarrollado en detalle* en clase.
- c) Bitácoras de avance, informe escrito y presentación oral; se recomienda orientar el tema, cuando los datos lo permitan, a riesgos, seguros, finanzas, crédito o segmentación.

Metodología

Se espera que la persona docente aplique al menos tres de las siguientes estrategias didácticas:

1. Clases magistrales con casos prácticos de modelación.
2. Laboratorios guiados en R o Python (el curso puede impartirse preferentemente en uno de los dos lenguajes; se permite que el estudiantado trabaje en el otro si demuestra dominio equivalente).
3. Proyecto grupal a lo largo del ciclo, con bitácoras de avance.
4. Búsqueda de datos y preguntas de investigación en fuentes externas.
5. Solución de problemas reales ligados a la industria o a contextos interdisciplinarios.
6. Visitas o charlas de personas expertas (banca, riesgos, segmentación u otros ámbitos de valor agregado).
7. Identificación de conceptos en artículos científicos sencillos e interpretación de resultados.
8. Peer project learning y retroalimentación entre pares en presentaciones.

Se motiva a la persona docente a incentivar un proyecto con alto componente computacional durante las 15 semanas del curso, la aplicación de modelos en la cuantificación de incertidumbre o riesgo, y la interpretación de resultados hacia público no especializado. Cuando la disponibilidad de datos lo permita, se recomienda orientar el proyecto a temas de riesgos, seguros, finanzas, crédito o segmentación, sin excluir otras aplicaciones matemáticas o científicas coherentes con el perfil del estudiantado.

Evaluación

La evaluación del aprovechamiento puede combinar, a criterio de la persona docente, los siguientes rubros (con ponderaciones definidas en la carta al estudiantado de cada oferta):

1. Tareas teóricas y de implementación.
2. Laboratorios evaluados (componente teórico y de programación).
3. Proyecto: bitácoras, presentaciones orales e informe escrito.
4. Examen o prueba integradora (opcional según la oferta).
5. Documentos sintéticos: póster, resumen (*abstract*), etc.

Bibliografía

1. James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning: With Applications in Python*. Springer. También la edición con aplicaciones en R.
2. Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

3. Trejos, J.; Castillo, W.; González, J. (2014). *Análisis Multivariado de Datos. Métodos y Aplicaciones*. Editorial de la Universidad de Costa Rica.
4. Breiman, L., Friedman, J., Olshen, R. y Stone, C. (1984). *Classification and Regression Trees*. Chapman and Hall/CRC.
5. Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
6. Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*.
7. Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly.
8. Wickham, H. y Golemund, G. (2017). *R for Data Science*. O'Reilly.
9. McKinney, W. (2022). *Python for Data Analysis*. O'Reilly.
10. Hair, J. F., Black, W. C., Babin, B. J. y Anderson, R. E. (2019). *Multivariate Data Analysis* (8th ed.). Cengage.
11. Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
12. Yu, B. y Barter, R. *Veridical Data Science: The Practice of Responsible Data Analysis and Decision Making*. <https://vdsbook.com/>