

MA-0404 Herramientas de ciencia de datos I

Año: II	Requisitos: MA-0341 Matemática Computacional
Ciclo: IV	Correquisitos: Ninguno
Tipo de curso: Teórico-práctico	Horas semanales: 5
Créditos: 4	Virtualidad: P, PV

Descripción del curso

Este curso está dirigido a estudiantes que poseen los conocimientos básicos de programación por lo que se ubica en el segundo año y segundo ciclo. Este curso, junto con Herramientas de Ciencias de Datos II, procura que el/la estudiante aprenda a utilizar y programar herramientas de software que son de uso frecuente en la ciencia de datos, así como en la elaboración de reportes y control de versiones de código. En específico, se busca que el estudiante aprenda a manejar hojas de cálculo, programar en el lenguaje estadístico R, utilizar $\text{\LaTeX}$ y Markdown e implementar repositorios en línea basados en Git.

Objetivo general

Proporcionar el conocimiento para utilizar y programar herramientas de software para la manipulación y visualización de datos, control de versiones de código y la elaboración de reportes.

Objetivos específicos

Al finalizar el curso el/la estudiante estará en la capacidad de:

1. Aplicar técnicas de manejo y depuración de datos en hojas de cálculo. (SC04, SC11, SH01.)
2. Usar los fundamentos básicos del lenguaje de programación R en problemas de exploración y visualización de tablas de datos. (SC04, SC11, SH01, SH06.)
3. Utilizar $\text{\LaTeX}$ y Markdown (RMarkdown) en la elaboración de informes y reportes. (SH09.)
4. Usar comandos básicos de GNU Bash en servidores basados en el sistema operativo Linux. (SH06.)
5. Implementar repositorios en línea basados en el sistema de control de versiones Git. (SH06, SH09.)

Contenidos

1. Manejo y buenas prácticas de datos en hojas de cálculo
 - a) Formateo de tablas de datos en hojas de cálculo.
 - b) Reducción de errores en el formateo de los datos.
 - c) Manejo de fechas de hojas de cálculos.

- d) Control de calidad y manipulación de datos en hojas de cálculo.
 - e) Exportar datos desde hojas de cálculo.
 - f) Estudio de casos sobre las limitaciones de las hojas de cálculo.
- 2. **Instalación y configuración de R y RStudio.** Instalación de paquetes en R.
- 3. **Introducción al lenguaje de programación R**
 - a) Objetos: matrices, listas y *data frames*.
 - b) Funciones y *scripts*.
 - c) Bucles y condicionales.
 - d) Código vectorizado.
- 4. **Creación de documentos con $\text{\LaTeX}$ y RMarkdown.** ProjectTemplate.
- 5. **Manejo de datos y visualización con R**
 - a) Visualización con `ggplot2`.
 - b) Transformación de datos con `tidyverse`: `dplyr`, `tidyr`.
 - c) Análisis exploratorio de datos: visualización de distribuciones; visualización de asociación entre variables.
 - d) Manejo de tablas en formato ancho/largo, datos *tidy*.
 - e) Manejo de cadenas de texto, fechas y factores.
- 6. **Introducción a Bash (UNIX).**
- 7. **Manejo de Git**
 - a) `git init`, `git commit`, `git push`, `git pull`.
 - b) Creación de repositorios en línea.

Metodología

Clases magistrales con laboratorios prácticos para demostrar las diferentes herramientas. Además, se le solicitará al estudiante que al finalizar el curso entregue un proyecto basado en un artículo científico o trabajo de investigación de posgrado en donde se le solicitará lo siguiente:

- Un repositorio *git* (GitHub/GitLab) con la historia de su proyecto.
- Código de la importación de datos ya sea mediante Excel o R.
- Código con la transformación de datos.
- Código con los *scripts* para visualizar sus datos.
- Reporte descriptivo con los hallazgos encontrados.

Incorporar ejemplos de tablas de datos relacionados con información financiera. La persona docente deberá incentivar la lectura de material relacionado con el curso en idioma inglés y el aprendizaje de conceptos básicos de estadística descriptiva a través del descubrimiento de los conceptos en datos reales.

Evaluación

1. Bitácoras parciales de proyecto.
2. Reporte final del proyecto.
3. Presentación del proyecto.

Bibliografía

1. Çetinkaya-Rundel, M., & Hardin, J. (2021). *Introduction to Modern Statistics* (1st ed.). OpenIntro. <https://openintro-ims.netlify.app/>
2. Data Organization in Spreadsheets for Ecologists (s/f). <https://datacarpentry.org/spreadsheet-ecology-lesson/>
3. Grolemund, G., & Wickham, H. (2014). *Hands-On Programming with R: Write Your Own Functions and Simulations*. O'Reilly Media. <https://rstudio-education.github.io/hopr/>
4. Kelion, L. (2020, 5 de octubre). Excel: Why using Microsoft's tool caused covid-19 results to be lost. BBC News. <https://www.bbc.com/news/technology-54423988>
5. Perez-Riverol, Y., et al. (2016). Ten Simple Rules for Taking Advantage of Git and GitHub. *PLOS Computational Biology*, 12(7), e1004947. <https://doi.org/10.1371/journal.pcbi.1004947>
6. Wickham, H., & Grolemund, G. (2016). *R for data science: import, tidy, transform, visualize, and model data* (First edition). O'Reilly.
7. Xie, Y. (2015). *Dynamic Documents with R and knitr* (2nd edition). Chapman and Hall/CRC.